

SAMSUNG INNOVATION CAMPUS

Diploma de Extensión Universitaria en IA · Edición 2025

Proyecto Final — Aprendizaje Supervisado**House Prices: Advanced Regression Techniques (Kaggle)**Fernando Martínez Plumed · fmartinez@dsic.upv.es**🔗 El proyecto en una página**

Aplicarás el flujo completo de aprendizaje supervisado a un problema real de regresión: predecir el precio de venta de viviendas en Ames (Iowa) usando 79 variables descriptivas.

Plataforma: Kaggle (competición pública).

Equipos: Hasta 3 integrantes. La nota se reparte por igual entre los miembros del grupo.

Entrega: Nada por escrito. Defensa oral de 15-20 min en la última sesión.

Métrica de Kaggle: RMSE sobre $\log(\text{SalePrice})$. Cuanto menor, mejor.

Tu objetivo no es solo el resultado de Kaggle, sino entender por qué tu modelo funciona y poder defenderlo.

1. La competición de Kaggle

Kaggle (www.kaggle.com) es la mayor plataforma mundial de competiciones de ciencia de datos. Empresas y organismos publican problemas reales, y la comunidad compite por encontrar las mejores soluciones. Trabajar con un problema de Kaggle te da tres ventajas frente a un proyecto inventado:

- Datos reales, complejos, sucios — como los del mundo profesional.
- Un baseline público y un leaderboard donde puedes ver cómo lo hacen otros.
- Una métrica de evaluación clara que no depende del criterio del profesor.

1.1 Sobre esta competición

Competición: *House Prices — Advanced Regression Techniques*.

Enlace: kaggle.com/competitions/house-prices-advanced-regression-techniques

Tipo: Regresión (la variable objetivo es continua: el precio de venta en dólares).

Datos: 1.460 viviendas de entrenamiento · 1.459 viviendas de evaluación · 79 atributos + Id.

2. Configuración inicial

Antes de tocar los datos, necesitas tres cosas:

1. Crea una cuenta de Kaggle en [kaggle.com](https://www.kaggle.com) (Sign in → manually create an account). Si ya tienes una, puedes usarla.
2. Configura tu nombre de usuario y de visualización siguiendo la convención del curso:



Convención de nombre de usuario

El User name y el Display name deben empezar por SAMSUNG_ seguido de los nombres de usuario de correo del grupo.

Individual: SAMSUNG_fermap1

Grupo de 3: SAMSUNG_user1_user2_user3

3. Únete a la competición desde el enlace anterior, acepta las reglas y descarga los ficheros train.csv y test.csv desde la pestaña Data.

3. Descripción de los datos

El conjunto de datos describe ventas residenciales reales en Ames, Iowa, entre 2006 y 2010. Originalmente se publicó como dataset educativo en sustitución del clásico "Boston Housing", añadiendo más variables y observaciones.

3.1 Resumen

Característica	Valor
Observaciones train	1.460 viviendas
Observaciones test	1.459 viviendas (sin SalePrice)
Total de atributos	79 predictores + Id + SalePrice
Tipo del objetivo	Continuo (precio en USD, regresión)
Rango de precios	\$34.900 – \$755.000 (media ≈ \$181.000)

3.2 Tipos de variables

Las 79 variables predictoras se dividen en cuatro grupos. Cada grupo requiere un tratamiento distinto en la fase de preprocesado:

Tipo	Cantidad	Ejemplos	Tratamiento típico
Continuas	20	LotArea, GrLivArea, TotalBsmtSF	Escalado, log si asimétricas
Discretas	14	FullBath, Bedroom, YearBuilt	A menudo se tratan como continuas
Categóricas nominales	23	Neighborhood, RoofStyle, SaleType	One-hot encoding
Categóricas ordinales	23	OverallQual, KitchenQual, GarageQual	Codificación ordinal (Po=1, Fa=2, ...)



¿Por qué importa esta clasificación?

La diferencia entre nominal y ordinal NO es cosmética. Una variable ordinal como KitchenQual tiene orden (Po < Fa < TA < Gd < Ex), y representarla con números

preserva esa información que un modelo puede aprovechar. Si la tratas como nominal y aplicas one-hot, pierdes el orden.

3.3 Variables clave que aparecen siempre en los modelos ganadores

De las 79 variables, estas suelen ser las más predictivas (úsalas como punto de partida):

Variable	Tipo	Significado
OverallQual	ordinal	Calidad general de materiales y acabados (1-10)
GrLivArea	continua	Superficie habitable sobre rasante (sq ft)
TotalBsmtSF	continua	Superficie total del sótano (sq ft)
GarageCars	discreta	Capacidad del garaje en coches
YearBuilt	discreta	Año de construcción
Neighborhood	nominal	Barrio dentro de Ames (~25 categorías)
BsmtQual	ordinal	Altura/calidad del sótano
KitchenQual	ordinal	Calidad de la cocina

3.4 La variable objetivo: SalePrice

SalePrice es continua (en USD) y, como muchos precios reales, tiene una distribución muy asimétrica a la derecha: hay muchas casas baratas y unas pocas casas muy caras. Esto causa dos problemas:

- La regresión lineal asume errores normalmente distribuidos. Con SalePrice tal cual, ese supuesto falla.
- La métrica de Kaggle es RMSE en escala logarítmica, así que los errores en casas baratas y caras pesan lo mismo. Si optimizas RMSE en escala original, sesgarás el modelo hacia las casas caras.

Truco fundamental: predecir $\log(\text{SalePrice})$

Aplica `np.log1p()` a SalePrice antes de entrenar. Entrena tu modelo para predecir el logaritmo. Cuando prediques en test, deshaz la transformación con `np.expm1()` antes de subir a Kaggle.

Esto normaliza la distribución del objetivo Y hace que tu RMSE local sea comparable con la métrica oficial de Kaggle.

4. Métrica de evaluación

Kaggle evaluará tu predicción con esta fórmula:

$$\text{RMSE} = \sqrt{\left(\frac{1}{N} \cdot \sum \left(\log(\hat{y}_i + 1) - \log(y_i + 1) \right)^2 \right)}$$

Es decir: el RMSE clásico, pero calculado entre los logaritmos de las predicciones y los valores reales. Tres consecuencias prácticas:

- Los errores en casas baratas pesan lo mismo que en casas caras (gracias al log).

- Las predicciones se pueden hacer en escala log internamente, y deshacerse con `expm1` al subir.
- Tu validación local debe usar la misma métrica: si calculas RMSE en dólares, no es comparable con tu score de Kaggle.

Para interpretar tu score en concreto:

- $RMSE \approx 0.10$ — buena puntuación (top ~25 % de la competición).
- $RMSE \approx 0.13\text{--}0.15$ — razonable, equivale a ~13–15 % de error relativo medio.
- $RMSE \geq 0.20$ — algo falta: revisa preprocesado, outliers, o prueba un modelo más expresivo.

5. Flujo de trabajo sugerido

Cualquier proyecto de aprendizaje supervisado profesional sigue las mismas seis fases. No saltes pasos: cada uno informa al siguiente.

Fase A — Análisis Exploratorio (EDA)

Qué: Entender los datos antes de modelar nada. Histogramas, scatter plots, mapas de correlación, tablas de frecuencias de categorías.

Por qué: Si no entiendes los datos, cualquier modelo es una caja negra que no podrás defender. La mitad de los puntos de Kaggle se ganan aquí.

Resultado: Una idea clara de qué variables importan, dónde hay outliers, qué transformaciones hacen falta.

Fase B — Limpieza y preprocesado

Qué: Tratar NaN, outliers y errores. Codificar variables categóricas. Escalar si tu modelo lo necesita.

Por qué: Muchos algoritmos no aceptan NaN. Los outliers (p.ej. 2 casas con `GrLivArea > 4000`) pueden distorsionar gravemente una regresión.

Resultado: Dos DataFrames limpios y numéricos (`X_train`, `X_test`) listos para entrenar.

Fase C — Ingeniería de características

Qué: Crear variables nuevas a partir de las existentes. Combinar áreas, ratios, indicadores binarios (`HasGarage`, `IsRemodeled`), edades calculadas (`Age = YrSold - YearBuilt`).

Por qué: Las variables originales rara vez son óptimas. Una característica bien diseñada vale más que un algoritmo más sofisticado.

Resultado: Un conjunto extendido con 5-20 variables nuevas, justificadas conceptualmente.

Fase D — Modelado

Qué: Probar varios algoritmos (regresión lineal regularizada Ridge/Lasso, Random Forest, Gradient Boosting, XGBoost). Tunear hiperparámetros con `GridSearchCV` o `RandomizedSearchCV`.

Por qué: Diferentes algoritmos capturan diferentes patrones. Comparar te dice qué tipo de no-linealidad importa en tus datos.

Resultado: Un modelo final elegido, con sus hiperparámetros justificados.

Fase E — Validación

Qué: Estimar honestamente el error que tendrás en el test set. Usa K-fold cross-validation ($k=5$ o $k=10$) sobre el conjunto de entrenamiento.

Por qué: Si solo te fías del score de Kaggle, irás a ciegas — solo puedes subir 5 ficheros al día. Tu CV local te permite iterar muchas más veces.

Resultado: Una estimación de RMSE con desviación estándar. Si tu CV dice 0.13 y Kaggle te da 0.18, hay overfitting.

Fase F — Envío y posicionamiento

Qué: Generar el CSV con (Id, SalePrice), subirlo a Kaggle, leer la posición y aprender de ella. Iterar.

Por qué: El leaderboard es feedback objetivo. Una caída grande entre tu CV y tu Kaggle score es un indicador de algo (data leakage, distribución distinta, etc.).

Resultado: Tu mejor envío + el rationale de por qué ese y no otro.

6. Consejos prácticos por fase

6.1 EDA (Fase A)

- Empieza por la distribución de SalePrice. Pinta histograma + boxplot. Verás la asimetría a la derecha y unos pocos extremos.
- Pinta un mapa de correlación para todas las variables numéricas frente a SalePrice. OverallQual, GrLivArea y TotalBsmtSF saldrán muy correladas.
- Dispersión SalePrice vs GrLivArea — identificarás 2-4 outliers obvios (casas muy grandes vendidas a precio muy bajo). Considera quitarlos del entrenamiento.
- Para variables categóricas, usa boxplots agrupados (uno por categoría) frente a SalePrice. Te dirán qué categorías importan.

6.2 Preprocesado (Fase B)

- Valores faltantes en variables numéricas: imputa con media o mediana (más robusta a outliers).
- Valores faltantes en variables categóricas: muchas veces NaN significa "no tiene" — p.ej. FireplaceQu = NaN casi siempre = "no hay chimenea". Crea una categoría "None" en vez de imputar la moda.
- Codificación ordinal con un mapping explícito {Po:1, Fa:2, TA:3, Gd:4, Ex:5}. No uses LabelEncoder (asigna orden arbitrario).
- Codificación nominal con `pd.get_dummies()` (one-hot). **Importante:** concatena train y test antes de aplicarlo para que tengan las mismas columnas finales.
- Aplica el log a la variable objetivo (`np.log1p`) y a las variables continuas más asimétricas (`skewness > 0.5`).

6.3 Ingeniería de características (Fase C)

- Áreas totales, p.ej. $\text{TotalSF} = \text{GrLivArea} + \text{TotalBsmtSF} + \text{GarageArea}$ suele ser muy predictiva.
- Edad de la casa: $\text{Age} = \text{YrSold} - \text{YearBuilt}$. Edad desde remodelación: $\text{AgeRemod} = \text{YrSold} - \text{YearRemodAdd}$.
- Indicadores binarios: HasPool, Has2ndFloor, IsRemodeled, HasGarage. Capturan la presencia/ausencia más que el detalle.
- Variables de interacción: $\text{OverallQual} \times \text{GrLivArea}$ suele ser muy predictiva (calidad y tamaño actúan multiplicativamente).

6.4 Modelado (Fase D)

- Empieza con una regresión lineal regularizada (Ridge o Lasso), es rápida y te da un baseline honesto.
- Prueba después un Random Forest (sin necesidad de escalado), captura no-linealidades automáticamente.
- XGBoost o GradientBoosting suelen ser los modelos ganadores en este tipo de competiciones. Aplica GridSearchCV sobre 2-3 hiperparámetros ($n_estimators$, max_depth , $learning_rate$).
- Combina predicciones de varios modelos (averaging o stacking), suele ganar 1-2% más en Kaggle.

6.5 Validación (Fase E)

- Usa $\text{KFold}(n_splits=5, shuffle=True, random_state=42)$ para que tus resultados sean reproducibles.
- Calcula RMSE sobre $\log(\text{SalePrice})$ en cada fold, luego haz la media. Esa media es tu "score local".
- Si CV local y Kaggle difieren mucho, investiga. ¿Hay data leakage? ¿Limpiaste outliers solo en train?

7. Ejemplo de baseline en Python

Un modelo muy simple, para que veas el formato y empieces a iterar. La intuición: las dos variables que más influyen suelen ser las que miden el tamaño total de la casa.

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import cross_val_score

# 1. Cargar datos
train = pd.read_csv('train.csv')
test = pd.read_csv('test.csv')

# 2. Seleccionar dos variables y aplicar log al target
X = train[['GrLivArea', 'TotalBsmtSF']].fillna(0)
y = np.log1p(train['SalePrice'])

# 3. Validar con 5-fold CV
model = LinearRegression()
```

```
scores = -cross_val_score(model, X, y, cv=5,
                          scoring='neg_root_mean_squared_error')
print(f'CV RMSE = {scores.mean():.4f} ± {scores.std():.4f}')
# Esperado: alrededor de 0.20 – modesto pero honesto

# 4. Entrenar en todo, predecir en test, deshacer log
model.fit(X, y)
X_test = test[['GrLivArea', 'TotalBsmtSF']].fillna(0)
preds = np.expml(model.predict(X_test))

# 5. Generar submission
submission = pd.DataFrame({'Id': test['Id'], 'SalePrice': preds})
submission.to_csv('submission.csv', index=False)
```

Con solo dos variables, RMSE ≈ 0.20 en CV. Tu trabajo es bajar de ahí, los mejores de Kaggle llegan a ~ 0.11 . Un modelo decente está en 0.13-0.14.

Recordatorio importante sobre el log

Si entrenas con $\log(\text{SalePrice})$, tu modelo predice $\log(\text{SalePrice})$. Antes de subir a Kaggle DEBES deshacer la transformación con $\text{np.expml}()$, o tu RMSE será ~ 10 (un desastre).

8. Envío a Kaggle

Formato esperado: un CSV con dos columnas, Id y SalePrice. Cabecera incluida. Ejemplo:

```
Id,SalePrice
1461,169000.1
1462,187724.1
1463,175221.0
...
```

Sube el archivo en Kaggle → Make a submission → Click or Drop. Tras unos segundos verás tu puntuación en el Public Leaderboard.

Límites y reglas

- Máximo 5 envíos al día por cuenta. Si llegas al límite, tendrás que esperar al día siguiente.
- No uses cuentas adicionales para saltarte el límite. Romper esta regla invalida la práctica.
- Sólo cuenta tu Public Leaderboard score (sobre el 50% del test set). Kaggle revela el Private Leaderboard al cerrar la competición.

9. Cómo se evalúa la práctica

La nota tiene cinco componentes. Los porcentajes son aproximados, el profesor evaluará el conjunto, pero esta tabla te indica dónde concentrar el esfuerzo.


Componente	Peso	Qué se valora
Preprocesado y comprensión de los datos	30 %	EDA realizado, tratamiento de NaN y outliers, codificación correcta de variables, justificación de decisiones.
Modelado	25 %	Variedad de modelos probados, tuning de hiperparámetros, justificación del modelo final elegido.
Validación	15 %	Cross-validation correctamente implementada, métricas comparables con la de Kaggle, consciencia del overfitting.
Resultado en Kaggle	15 %	Cuanto menor el RMSE, mejor. Importante también: que ese score se haya enviado realmente.
Defensa oral	15 %	Claridad, capacidad de síntesis, dominio del código propio, respuestas a preguntas.

Lo más importante de todo

Aunque hayas probado 20 cosas, en la defensa elige UN modelo y defiéndelo. El profesor valorará MUY positivamente la claridad y la capacidad de síntesis. Es mejor explicar bien un modelo razonable que explicar mal el mejor de Kaggle.

Para aspirar al 10

Para poder aspirar a la máxima puntuación, debes superar la puntuación del profesor:



10. Día de la evaluación

La defensa será en la última sesión, 15-20 minutos por grupo. No hay que entregar nada por escrito. Lleva todo preparado para enseñar en directo desde tu portátil.

10.1 Qué traer

- Tu notebook (Jupyter, Colab, Kaggle Kernel, ...lo que prefieras) con todo el código ejecutable de principio a fin.
- Un resumen mental de tu mejor envío a Kaggle: posición, score, fecha.
- El nombre de usuario de Kaggle del grupo (siguiendo la convención SAMSUNG_...). El profesor lo verificará.
- Cualquier referencia o código de la comunidad que hayas usado, debes citarlos.

10.2 Estructura sugerida de la defensa

- Qué viste en los datos. Los dos o tres descubrimientos clave de tu EDA y las decisiones de preprocesado que tomaste por ellos.
- Qué modelo usaste y por qué ese. Hiperparámetros principales.
- Resultado: CV local y score Kaggle. Diferencias entre ambos (si las hay) y tu explicación.

- Uso de notebooks, LLMs, etc. Que has aprendido, dónde te ha fallado, que has modificado, etc.
- Dudas y cuestiones por parte del profesor.

11. Recursos útiles

- Página oficial de la competición: kaggle.com/competitions/house-prices-advanced-regression-techniques
- Documentación detallada del dataset original (Cock, 2011): www2.amstat.org/publications/jse/v19n3/decock/DataDocumentation.txt
- Mapa de barrios de Ames (útil para entender Neighborhood): www2.amstat.org/publications/jse/v19n3/decock/AmesResidential.pdf
- Sección Code de la propia competición de Kaggle: cientos de notebooks públicos. Léelos, inspírate, pero CITA lo que reutilices.
- Sección Discussion: dudas frecuentes y trucos compartidos por participantes.

Honestidad académica

Está permitido — y recomendado — leer notebooks públicos de Kaggle, foros y la documentación oficial, así como el uso de LLMs.

Es obligatorio citar en la defensa cualquier fragmento de código o idea estructural que provenga de una fuente externa. Si un compañero te pasa una función o un mapping, también se cita. No citar es plagio y se penaliza.

Apéndice — Referencia completa de las 80 variables

Para uso durante el desarrollo. La tabla recoge cada atributo con su tipo y una descripción breve. Para más detalles consulta el [DataDocumentation.txt](#) enlazado en §11.

Atributo	Tipo	Descripción
Id	—	Identificador
MSSubClass	nominal	Clase de edificio
MSZoning	nominal	Clasificación general de zonificación
LotFrontage	continua	Metros de calle conectados a la propiedad
LotArea	continua	Superficie del solar (sq ft)
Street	nominal	Tipo de acceso por carretera
Alley	nominal	Tipo de acceso por callejón
LotShape	ordinal	Forma general del solar
LandContour	nominal	Llanura del terreno
Utilities	ordinal	Tipo de suministros disponibles
LotConfig	nominal	Configuración del solar
LandSlope	ordinal	Pendiente del terreno
Neighborhood	nominal	Barrio dentro de Ames
Condition1	nominal	Proximidad a carretera/vía
Condition2	nominal	Proximidad a otra carretera/vía
BldgType	nominal	Tipo de vivienda
HouseStyle	nominal	Estilo de vivienda
OverallQual	ordinal	Calidad general de materiales y acabados (1-10)
OverallCond	ordinal	Estado general de conservación (1-10)
YearBuilt	discreta	Año de construcción
YearRemodAdd	discreta	Año de remodelación
RoofStyle	nominal	Tipo de tejado
RoofMatl	nominal	Material del tejado
Exterior1st	nominal	Material exterior principal
Exterior2nd	nominal	Material exterior secundario
MasVnrType	nominal	Tipo de chapado de mampostería
MasVnrArea	continua	Área de chapado de mampostería (sq ft)
ExterQual	ordinal	Calidad del material exterior
ExterCond	ordinal	Estado del material exterior
Foundation	nominal	Tipo de cimentación
BsmtQual	ordinal	Altura del sótano
BsmtCond	ordinal	Estado general del sótano
BsmtExposure	ordinal	Exposición del sótano (walkout / garden)

BsmtFinType1	ordinal	Calidad del acabado del sótano (zona 1)
BsmtFinSF1	continua	Superficie acabada del sótano zona 1 (sq ft)
BsmtFinType2	ordinal	Calidad del acabado del sótano (zona 2)
BsmtFinSF2	continua	Superficie acabada del sótano zona 2 (sq ft)
BsmtUnfSF	continua	Superficie sin acabar del sótano (sq ft)
TotalBsmtSF	continua	Superficie total del sótano (sq ft)
Heating	nominal	Tipo de calefacción
HeatingQC	ordinal	Calidad y estado de la calefacción
CentralAir	nominal	Aire acondicionado central
Electrical	ordinal	Sistema eléctrico
1stFlrSF	continua	Superficie planta baja (sq ft)
2ndFlrSF	continua	Superficie planta primera (sq ft)
LowQualFinSF	continua	Superficie acabada de baja calidad (sq ft)
GrLivArea	continua	Superficie habitable sobre rasante (sq ft)
BsmtFullBath	discreta	Baños completos en el sótano
BsmtHalfBath	discreta	Aseos en el sótano
FullBath	discreta	Baños completos sobre rasante
HalfBath	discreta	Aseos sobre rasante
Bedroom	discreta	Dormitorios sobre rasante
Kitchen	discreta	Número de cocinas
KitchenQual	ordinal	Calidad de la cocina
TotRmsAbvGrd	discreta	Habitaciones sobre rasante (excl. baños)
Functional	ordinal	Funcionalidad de la vivienda
Fireplaces	discreta	Número de chimeneas
FireplaceQu	ordinal	Calidad de la chimenea
GarageType	nominal	Localización del garaje
GarageYrBlt	discreta	Año de construcción del garaje
GarageFinish	ordinal	Acabado interior del garaje
GarageCars	discreta	Capacidad del garaje en coches
GarageArea	continua	Superficie del garaje (sq ft)
GarageQual	ordinal	Calidad del garaje
GarageCond	ordinal	Estado del garaje
PavedDrive	ordinal	Camino de acceso asfaltado
WoodDeckSF	continua	Área de terraza de madera (sq ft)
OpenPorchSF	continua	Área de porche abierto (sq ft)
EnclosedPorch	continua	Área de porche cerrado (sq ft)
3SsnPorch	continua	Área de porche de tres estaciones (sq ft)

ScreenPorch	continua	Área de porche con mosquitera (sq ft)
PoolArea	continua	Área de piscina (sq ft)
PoolQC	ordinal	Calidad de la piscina
Fence	ordinal	Calidad de la cerca
MiscFeature	nominal	Característica miscelánea (ascensor, 2º garaje, ...)
MiscVal	continua	Valor en \$ de la característica miscelánea
MoSold	discreta	Mes de venta
YrSold	discreta	Año de venta
SaleType	nominal	Tipo de venta
SaleCondition	nominal	Estado de la venta
SalePrice	continua	Precio de venta en USD (VARIABLE OBJETIVO)